Rapport d’évaluation

Expérience principale : retrouver quinze faux raccords introduits dans un même scénario

1. Données, droits et protocole

Valkaama, Tim Baumann d’après Hendrik Behnisch, version 2007-06-30 : 56 scènes conservées. L’adaptation d’évaluation ajoute 19 accessoires et prépare leur continuité cohérente. **Exactement quinze phrases ultérieures sont ensuite modifiées** pour créer quinze erreurs ; quatre transitions expliquées restent comme contrôles négatifs. L’évaluation couvre S001–S012, où se trouvent toutes les injections. Aucun faux raccord n’est attribué aux auteurs originaux.

La page officielle de l’auteur annonce la licence **CC BY-SA 3.0**. L’adaptation est attribuée, ses modifications documentées et sa licence identique. Les contrôles vérifient les preuves littérales et que l’annulation des quinze modifications restitue la référence : **validation réussie**. Annotations proposées avec assistance IA, relecture humaine non attestée ; jeu de développement visible.

Le système utilise le pipeline du produit : extraction par lots de trois scènes, contrôle des citations, suivi des états, BM25 puis comparaison LLM. Protocole baseline, même modèle : les mêmes 12 scènes en deux moitiés de 6 scènes, deux appels sans mémoire ni RAG ; aucune annotation fournie. Chaque paire annotée tient dans une moitié.

Modèle : `openai/gpt-oss-120b` via groq, température 0, licence Apache-2.0. Pipeline `317d4f315597`.

Profil continuity-free-v1 : extraction 3 scènes / 3000 tokens ; jugement 2 candidats / 1000 tokens ; baseline 2 × 6 scènes / 3000 tokens. Hash b0ebadb133d2.

2. Résultats par alerte et incertitude

Un vrai positif (VP) identifie l’accessoire annoté avec deux preuves valides ; une seule détection compte par injection. Alerte erronée, dupliquée ou preuve non conforme : faux positif (FP). Injection sans détection conforme : faux négatif (FN). Ici, le FP baseline est une citation approximative de la montre, pas une contradiction inventée.

Précision = VP / (VP + FP), parmi les alertes contrôlables. **Rappel = VP / 15**, parmi les erreurs introduites. F1 : moyenne harmonique. Les alertes sur les objets originaux non annotés sont exclues de la précision contrôlée et restent à relire.

Méthode	VP / FP / FN	Précision [IC 95 %]	Rappel [IC 95 %]	F1
Prompt simple	6 / 1 / 9	85,7 % 48,7 %–97,4 %	40,0 % 19,8 %–64,3 %	54,5 %
Extraction + RAG + comparaison	7 / 0 / 8	100,0 % 64,6 %–100,0 %	46,7 % 24,8 %–69,9 %	63,6 %

> **Mesure réelle du système et de la baseline disponible.** 7 alertes système, dont 0 hors périmètre annoté ; 7 alertes baseline, dont 0 hors périmètre. 8/15 injections manquées ; une précision observée de 100 % ne garantit pas ce niveau sur un autre scénario.

IC de Wilson à 95 % descriptifs : erreurs construites et dépendantes, une seule œuvre, faible effectif. Ils ne prouvent pas une généralisation à d’autres films.

3. Échecs et preuve affichée

Injections manquées : E03, E04, E06, E07, E08, E11, E12, E15

Piste dans les traces : E03/E06/E12 sont extraits comme remplissages malgré la négation ; diagnostic à relire. Chaque alerte affiche ses deux passages, scène et page. Une citation exacte ne garantit pas une interprétation juste.

Coût, compléments et limites

Les expériences suivantes ont leur propre unité et leur propre modèle

4. Coût et durée de l’expérience principale

Douze scènes	Tokens entrée / sortie	Durées cumulées	Coût estimé
Prompt simple (2 requêtes)	7 531 / 1 088	41,093 s	0,001782 USD
Pipeline (8 requêtes)	22 344 / 6 085	184,217 s	0,007003 USD

Tarif openai/gpt-oss-120b, vérifié le 2 novembre 2026 : 0.15 USD/M en entrée, 0.6 USD/M en sortie. Coût théorique des sorties mesurées, hors essais et facture réelle. Les durées additionnent les requêtes, y compris quotas et réponses reprises du cache ; la dernière reprise seule (93,072 s) n’est pas la durée totale. 8 requêtes système pour 6 appels logiques, le transport divisant le jugement.

5. Expériences secondaires

50 vignettes synthétiques réservées au test, dix autres cas ayant servi au développement. Unité : cas positif si au moins une alerte, différente de l’unité du benchmark principal. Modèle `openai/gpt-oss-20b`, 2 novembre 2026, code `fc3b8d431ac6`. Annotations assistées par IA à relire.

Par cas synthétique	Précision [IC 95 %]	Rappel	F1
Prompt simple	84,0 % [65,3 %–93,6 %]	100,0 %	91,3 %
Pipeline	94,4 % [74,2 %–99,0 %]	81,0 %	87,2 %

Le prompt simple a ici le meilleur F1 ; le pipeline émet moins de fausses alertes. Ces scores historiques ne valident pas rétroactivement le nouveau modèle.

24 questions sur les dix premières scènes inchangées de Valkaama, profil `openai/gpt-oss-120b` : 19/24 conformes avec RAG [IC 95 % 59,5 %–90,8 %], contre 16/24 au prompt simple [46,7 %–82,0 %]. Abstentions correctes : 4/4 et 4/4. La grille lexicale vérifie réponse et citation, ou `NOT FOUND`. Synonymes et négations peuvent la tromper. Cette mesure porte sur les réponses, pas la continuité.

Recherche seule : 12 requêtes lexicales, scène attendue dans les cinq premiers résultats : 100,0 %. Cela ne mesure pas la justesse d’une analyse.

6. Sécurité, portée et travaux restants

3/3 essais adversariaux réels résistants aux attaques testées. Citations et identifiants contrôlés ; documents traités comme données ; clé absente des prompts ; sorties non exécutées. Trois essais ne garantissent pas une sécurité générale.

Le besoin métier et le gain de temps ne sont pas validés. Relecture humaine des annotations à consigner. Objets homonymes, transferts implicites et flashbacks restent difficiles. L’analyse porte uniquement sur le texte ; images, audio et vidéo ne sont pas pris en charge.

> Une œuvre et des erreurs construites ne suffisent pas à généraliser. Réserver un autre scénario annoté avant de conclure.

Preuves : rapports JSON dans `eval/` ; annotations et licence dans `data/controlled-script/`. Reproduction sans appel : `node eval/controlled-run.mjs`. Les chemins complets figurent dans la version Markdown.