Rapport d’évaluation

Continuité textuelle des accessoires · résultats du prototype et limites de leur interprétation

1. Protocole de continuité

Le jeu comporte **60 cas synthétiques contrôlés** : dix de développement et cinquante réservés au test (21 positifs, 29 négatifs). États, possession, réparations, objets homonymes, ellipses, absences de mention et injections sont représentés. Les annotations assistées par IA **attendent une validation étudiante**.

Le prompt simple reçoit le texte intégral du cas. Le système reçoit les mêmes scènes : extraction JSON, validation des citations, suivi d’objets, recherche BM25 puis comparaison LLM. Modèle et température identiques ; tous les appels du système sont comptés.

Référence : openai/gpt-oss-20b sur groq · prompts v1.0.0 · température 0 · raisonnement low · code `fc3b8d431ac6`. Les nouveaux réglages du produit n’héritent pas de ces scores.

2. Résultats et incertitude

L’unité est le **cas** : au moins une alerte rend la prédiction positive. Précision = VP / (VP + FP) ; rappel = VP / (VP + FN) ; F1 = moyenne harmonique. Les intervalles de Wilson à 95 % rendent visible le petit effectif.

Méthode	Précision [IC 95 %]	Rappel	F1	Médiane
Prompt simple	84,0 % 65,3 %–93,6 %	100,0 %	91,3 %	0,508 s
Extraction + RAG + comparaison	94,4 % 74,2 %–99,0 %	81,0 %	87,2 %	6,426 s

Système : 17 VP · 1 FP · 4 FN · 28 VN. Baseline : 21 VP · 4 FP · 0 FN · 25 VN. Erreurs fournisseur : 0 système, 0 baseline. IC du rappel : 60,0 %–92,3 % système ; 84,5 %–100,0 % baseline.

> **Le prompt simple obtient le meilleur F1.** Le pipeline réduit les fausses alertes de 4 à 1, mais manque 4 cas positifs. Sa supériorité globale n’est pas démontrée. La borne basse de la précision ne confirme pas un seuil de 80 %.

3. Échecs à expliquer

- **Quatre faux négatifs de possession** : C013, C024, C032, C059. Un passeport conservé par un agent réapparaît chez sa propriétaire sans restitution décrite.
- **Un faux positif temporel** : C051. Un lecteur cassette cassé est vu intact dans une séquence située cinq ans plus tôt.

Les cas sont courts, synthétiques et parfois proches. Leurs intervalles ne corrigent pas ce biais et ne prédisent pas la performance sur un film. Après lecture des erreurs, toute correction doit être évaluée sur de nouveaux cas indépendants.

Données réelles et limites

Mesures complémentaires · coût · sécurité · travail restant

4. Questions sur un vrai scénario

24 questions sur Valkaama : vingt informations présentes et quatre absentes. Même corpus : dix scènes intégrales pour la baseline, passages retrouvés pour le RAG. Profil QA `openai/gpt-oss-120b`, distinct de la continuité 20B.

Méthode	Réussite [IC 95 %]	Abstentions correctes	Médiane
Prompt simple	16/24 · 66,7 % 46,7 %–82,0 %	4/4	57,003 s
Questions avec RAG	19/24 · 79,2 % 59,5 %–90,8 %	4/4	0,573 s

Grille : éléments lexicaux, scène et référence dans la réponse, ou `NOT FOUND` sans citation. Synonymes et négations limitent ce contrôle ; relecture nécessaire. Les durées incluent la régulation du quota.

Exécution : 2 novembre 2026, openai/gpt-oss-120b, code 317d4f315597. Erreurs fournisseur : 0. Échecs système : QA008, QA012, QA013, QA016, QA018. Cette mesure concerne les réponses, pas la détection de continuité.

5. Recherche, tokens et coût

Sur 12 recherches lexicales dans Valkaama, la scène de référence apparaît dans les cinq premiers résultats dans **100,0 %** des cas. Les citations sont contrôlées dans le texte. Ce résultat mesure la recherche seule.

50 cas synthétiques	Tokens entrée / sortie	Coût estimé / cas
Prompt simple	12 977 / 4 449	0,000046 USD
Pipeline	45 405 / 16 483	0,000167 USD

Tarif catalogue openai/gpt-oss-20b, vérifié le 2 novembre 2026 : 0.075 USD/M en entrée et 0.3 USD/M en sortie. Estimation hors cache, remises et plan gratuit, distincte d’une facture. Les quotas et le volume d’un scénario modifient coût et latence.

6. Sécurité et portée

3/3 essais adversariaux réels ont résisté aux attaques testées : instruction dans le scénario, demande de secret et détournement de la question. Cet échantillon ne garantit pas la résistance générale aux injections.

Les citations extraites sont recherchées après normalisation ; les identifiants inventés sont rejetés. Un passage présent ne garantit pas une interprétation correcte. La validation humaine reste nécessaire.

> **Validation d’usage :** les retours internes ont guidé le parcours et les explications. Le test entre les trois membres reste à consigner ; il ne prouve pas un gain de temps en tournage. Faire relire les références et réserver de nouveaux cas avant de modifier le détecteur.

Sources et preuves : `eval/report.json`, `eval/qa-real-report.json`, `eval/retrieval-real.json`, `eval/red-team-results.json`. Méthodes reproductibles dans `eval/`. Tarifs : documentation Groq. Attribution du scénario et droits : `data/README.md`.