Fiche système

Aide à la relecture de continuité des accessoires d’un scénario

Usage prévu

Scriptes et petites équipes de court métrage préparant le suivi des accessoires. Le produit rassemble des mentions et propose des points sourcés à examiner. Le besoin et le gain de temps restent à valider avec une personne réelle.

Entrées et sorties

PDF avec texte, TXT, Fountain, Markdown. Scènes et pages, accessoires, mentions, deux passages par point signalé, décision et note de revue. Export du projet JSON et du rapport Markdown.

Modèle de référence

`openai/gpt-oss-20b` via Groq : MoE 20B, 3,6B actifs, licence Apache 2.0 ; température 0 et raisonnement low. Précision d’infrastructure TruePoint gérée par Groq, pas par l’équipe. L’API ne propose pas de snapshot immuable.

Ollama et autres modèles en option. Licence, mémoire et compatibilité à vérifier pour chaque choix. Les nouveaux paramètres sont conservés avec l’analyse ; changer la configuration impose une nouvelle évaluation.

Fonctionnement

Segmentation déterministe ; extraction JSON par lots ; contrôle des citations ; suivi des objets ; candidats d’état ou de possession ; BM25 puis comparaison LLM ; revue humaine. Les questions utilisent recherche, réponse citée ou abstention.

Données et droits

Valkaama, Tim Baumann d’après Hendrik Behnisch, version 2007-06-30 : 56 scènes, CC BY-SA 3.0, pages conservées. Les Heures Creuses et le benchmark de continuité sont synthétiques.

MovieSum : catalogue externe facultatif, hors benchmark. Sa licence de jeu déclarée CC BY-NC 4.0 ne garantit pas les droits des œuvres sous-jacentes. Imports avec provenance et portée explicites.

Protections et confidentialité

Clés côté serveur ; limites de fichier, pages et texte ; citations et identifiants contrôlés ; documents traités comme données ; sorties non exécutées. Groq reçoit les scènes ou extraits utiles ; Ollama permet l’inférence locale. Les projets restent sur l’appareil, sans synchronisation d’équipe.

Hors périmètre et limites

Pas de vidéo, d’OCR ni de planning de tournage. L’ordre narratif n’est pas reconstruit. Identité des objets, flashbacks et transferts implicites difficiles ; RAG lexical limité sur les paraphrases et les langues croisées. Les citations ne prouvent pas la justesse d’une conclusion.

Évaluation disponible

50 cas synthétiques réservés, annotations assistées par IA à relire. **Précision par cas signalé 94,4 % [74,2 %–99,0 %], rappel 81,0 %, F1 87,2 %.** Baseline : précision 84,0 %, rappel 100,0 %, F1 91,3 %. Le pipeline réduit les fausses alertes mais n’est pas globalement supérieur.

Le jeu de 24 questions réelles existe ; sa comparaison complète reste à vérifier. Recherche seule : 12 requêtes, rappel de scène à 5 de 100,0 %. Red team : 3/3 essais réussis ; portée limitée.

Responsables et contact : **équipe de trois — à renseigner**. Détails : `docs/evaluation_report.md`, `docs/use_policy.md`, `docs/red_team_log.md`, `data/README.md`. Les rapports bruts conservent leurs dates, modèles et références de code.